一年与两年数据对比测评

下载 PDF · 项目首页 · 完整结果索引

DS6004 Group 7 · 新加坡牛车水 8 个停车场 · 2026-11-06

01 / 两年历史小幅改善占用率预测

相同测试期内，两年历史使 M0 / M1 的 MAE 降低约 1.3%-1.7%；风险预测与推荐尚无显著改善。

新文件覆盖 2024-11-05 至 2026-11-04。我们从这份修正版中截取最近一年，重新运行一年、两年共享测试期、两年标准切分三组 A → B → C，避免把旧数据清洗差异误当成历史长度效果。

公平比较设置	最近一年	两年历史
训练日期数	219	584
共同验证段	2026-06-12 至 08-23，73 天	相同
共同测试段	2026-08-24 至 11-04，73 天	相同

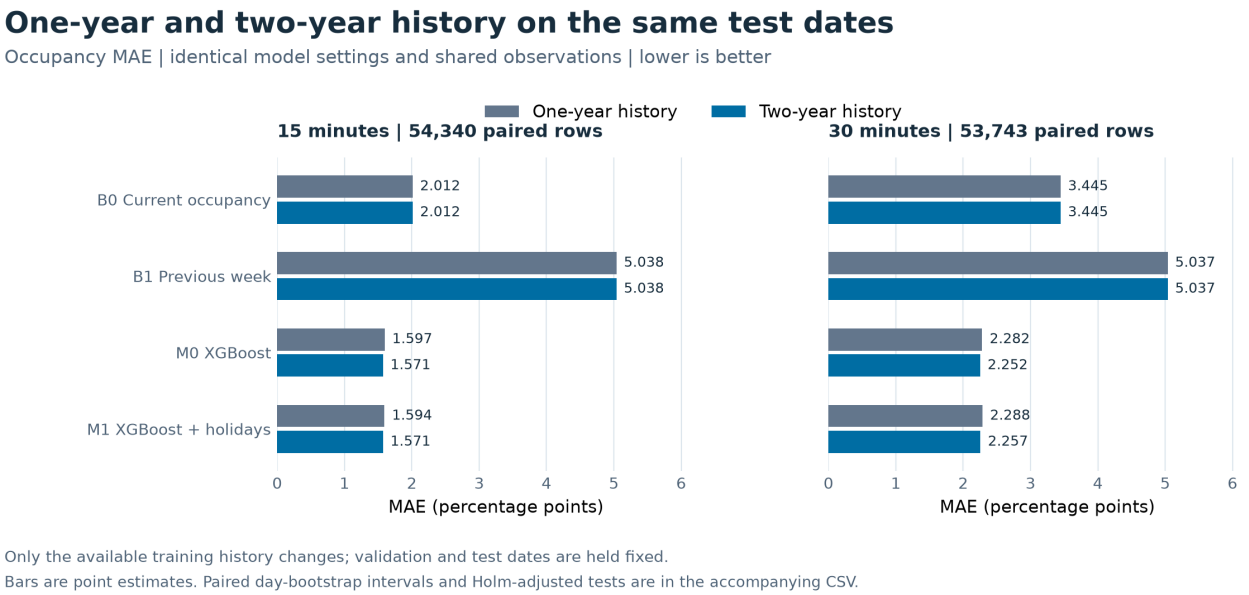


图 1 | 同一测试期的占用率 MAE，单位为占用率百分点，越低越好。

M0 为 XGBoost；M1 额外加入假日标记。15 / 30 分钟的 M0 MAE 从 1.5970 / 2.2823 降至 1.5706 / 2.2519 个百分点，相对降低 1.65% / 1.34%。M1 分别降低 1.44% / 1.39%；四项按日配对检验的 Holm 校正 p 均约 0.0012。

共同可评分样本为 54,340 / 53,743 个停车场与时点。模型、特征、超参数与验证日期固定；只有训练历史向前扩展。两年共享切分约为 80% / 10% / 10%，专用于历史长度实验；proposal 的标准 60% / 20% / 20% 另行运行。

配对预测统计 · 对齐审计

02 / 更多历史没有带来全面提升

“占用率更准”与“到达时能停到”是两个问题，需要分别检验。

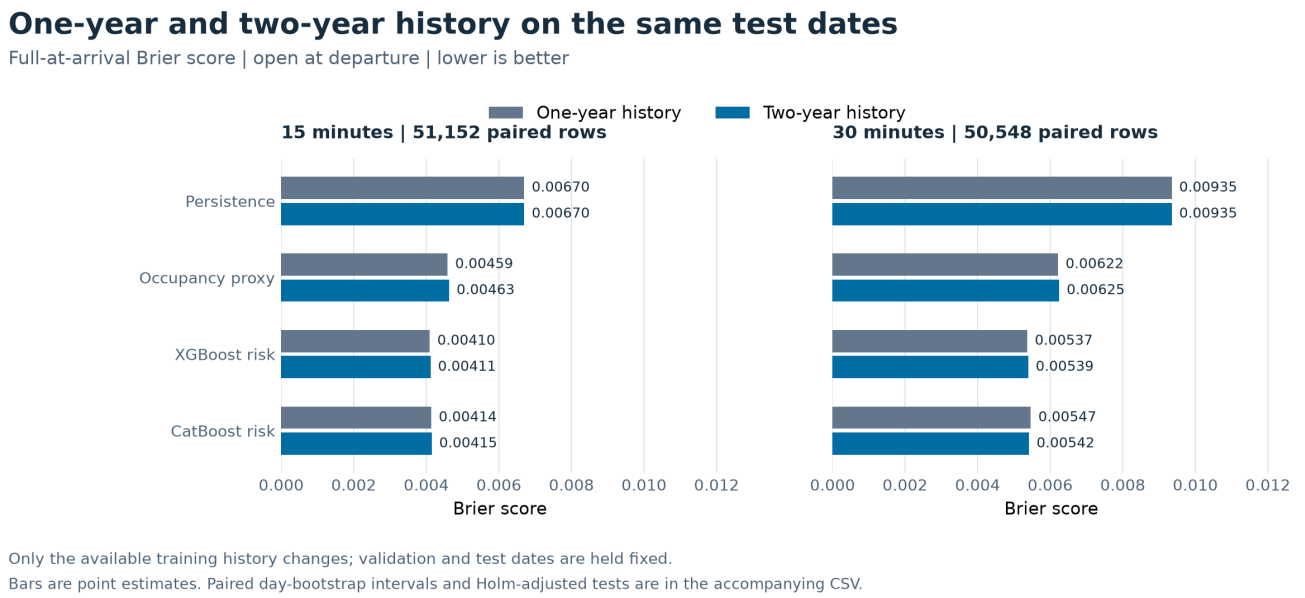


图 2 | 在出发时有位的同一组测试样本上比较到达满位概率。Brier 为概率平方误差，越低越好。

满位概率模型	时长	一年 Brier	两年 Brier
XGBoost	15 分钟	0.004096	0.004115
XGBoost	30 分钟	0.005368	0.005394
CatBoost	15 分钟	0.004137	0.004149
CatBoost	30 分钟	0.005466	0.005418

以上四项的 Holm 校正 p 均为 1；全部历史长度风险比较均未达到校正后 $p < 0.05$。数值有升有降，不能据此宣称两年风险模型更好，也不能解释为两者等效。两种历史长度都使用独立时间验证段校准，测试段只评分。

推荐回放也使用相同出发时点、候选场、目的地和距离权重 0.50。15 / 30 分钟分别有 6,794 / 6,786 个匹配场景；两组所有策略的首选满位与少于 3 个空位次数都为 0。两年策略 C 的平均距离只减少约 0.15 / 0.42 米，未通过多重校正；全部策略的历史长度差异均无统计显著性。

共同测试期没有公共假日，最近场 KAM 本身也没有满位。近满子集的占用率误差随历史增加而下降，但 15 分钟 M0 / M1 仍略逊于当前状态 B0；局部预测提升不等于停车失败率下降。

风险配对统计 · 策略配对统计

03 / 完整两年按 proposal 独立测评

> 标准 60% / 20% / 20% 运行保留 146 个测试日期；这组分数不能直接拿来比较一年与两年。

标准两年运行按时间分为 438 天训练、146 天验证、146 天测试。验证从 2026-01-17 开始，测试从 2026-06-12 开始；两个边界前各隔离 30 分钟。测试结束于 2026-11-04。

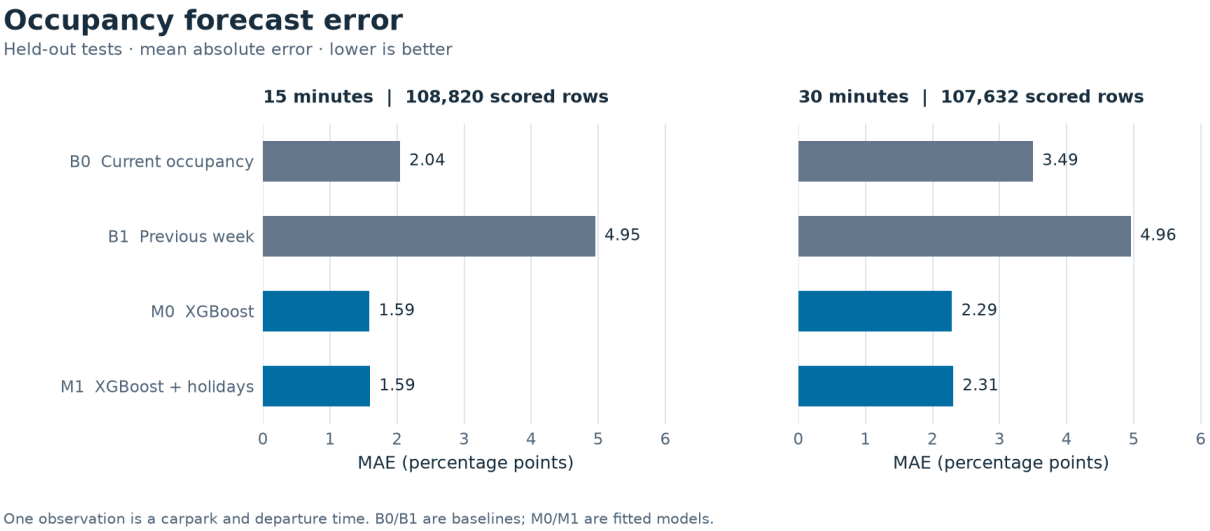


图 3 | 标准两年运行的共同测试样本 MAE。B0 沿用当前状态，B1 使用上周同刻。

预测时长	共同测试样本	B0 MAE	M0 MAE	M1 MAE
15 分钟	108,820	2.0409	1.5859	1.5930
30 分钟	107,632	3.4949	2.2882	2.3061

单位为占用率百分点。M0 相比当前状态 B0 的总体误差分别降低约 22.3% / 34.5%。这回答“模型是否优于基准”，第 1 页才回答“增加历史是否有帮助”。

本组测试期有 2 个公共假日日期，假日共同样本为 1,504 / 1,488 条。假日子集 M0 的 MAE 为 1.8063 / 2.6037，M1 为 1.7820 / 2.5248 个百分点。只有两个日期，结果只作描述，尚不足以证明加入假日特征具有稳定收益。

历史长度实验与标准两年实验的测试日期、训练日期、校准段和推荐权重不同，不应按数字大小横向排名。M0 / M1、XGBoost / CatBoost 均事先保留，未根据测试结果重新调参。

标准两年预测指标 · 分停车场指标

04 / 回应老师：预测到达无位风险

分开建模真正满位与安全余量不足，并在未参与训练的时间段校准概率。

标准两年测试的出发有位样本为 102,649 / 101,451 条，15 / 30 分钟后满位分别发生 733 / 1,015 次。以下比较只在相同样本上进行，不把出发时已满的情况混入主要风险评分。

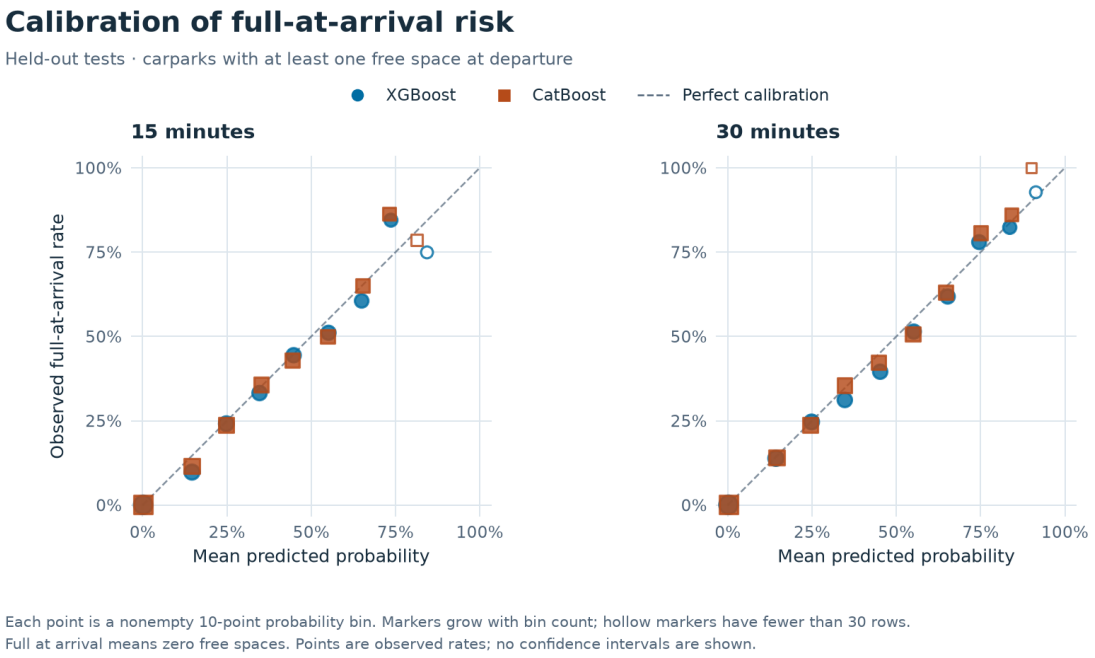


图 4 | 标准两年测试期的满位风险校准。横轴是预测概率，纵轴是实测发生率；接近对角线表示校准较好。

模型	15 分钟 Brier	30 分钟 Brier	15 / 30 分钟 AP
占用率风险代理	0.004991	0.006708	0.472 / 0.516
XGBoost 直接风险	0.004481	0.005734	0.527 / 0.605
CatBoost 直接风险	0.004505	0.005756	0.525 / 0.601

XGBoost 相对占用率风险代理的 Brier 降低约 10.2% / 14.5%，Holm p 均约 0.0024；XGBoost 与 CatBoost 的满位 Brier 差异未达显著性。AP 越高越好，但不能替代概率校准。

真正满位定义为到达空位 = 0；安全余量不足定义为到达空位 < 3；proposal 的近满定义为空位 < 容量的 10%。三个事件分别输出，不能把预警事件算成真实失败。校准图采用固定 10 个百分点分箱；空心点少于 30 条，高概率档稀少，未画置信区间。

风险指标与低余位结果 · 校准分箱

05 / 推荐的距离与安全余量权衡

完整两年回放观察到策略差异，但还不能据此宣称预测策略降低了真实司机的失败率。

目的地为牛车水地铁站 A 出口，8 场在 1 公里内；验证段选定距离权重 0.25。下表 visitor_eligible 按访客开放时间和完整观测筛选，可包含出发时已满的候选；15 / 30 分钟有 13,597 / 13,586 个匹配出发时点。

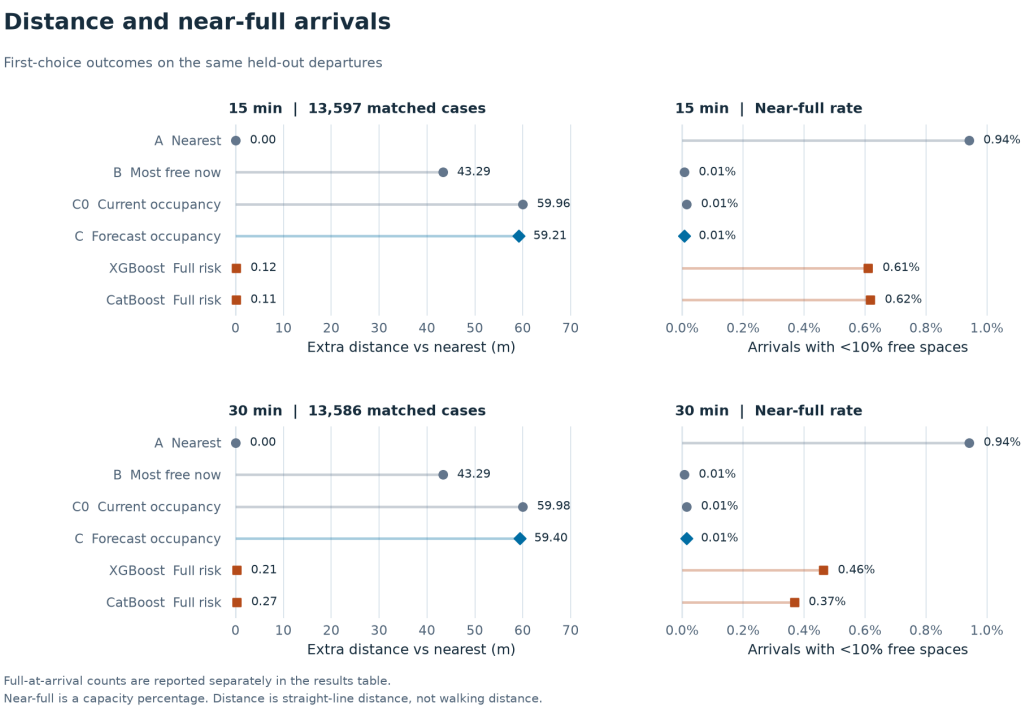


图 5 | 标准两年测试期的额外直线距离与近满率。按比例近满与真正满位不同。

策略	15 / 30 分钟满位次数	15 / 30 分钟近满次数	平均距离（米，15 / 30）
A 最近	28 / 28	128 / 128	202.11 / 202.11
B 当前空位最多	0 / 0	1 / 1	245.40 / 245.41
C0 当前占用率	1 / 2	2 / 2	262.08 / 262.10
C 预测占用率	1 / 2	1 / 2	261.32 / 261.51
XGBoost 满位风险	0 / 0	83 / 63	202.23 / 202.32
CatBoost 满位风险	0 / 1	84 / 50	202.22 / 202.39

A 的 28 次满位只集中在 8 月 16 日和 18 日；open_at_departure 再排除出发时已满的候选后，A 的到达满位为 4 / 7 次。因此 28 与 0 的差别不能全部归功于预测了途中变化。

C 相比 C0 的满位次数相同；直接风险策略相较 C0 距离约少 60 米，但近满率更高，两项 Holm p 均约 0.0038，满位差异不显著。这是固定两年数据下的策略权衡，与第 2 页历史长度比较不同。

两种候选口径与全部指标 · 配对统计

06 / 数据修正、统计边界与交付

新数据质量

核查项	结果
覆盖	730 天，560,637 行，8 个停车场，无重复键
可用记录	549,569 行，占 98.03%；无效行 11,068，不插补
缺少网格	3 条，正是旧年表中 PRM 的容量异常时点
标签核对	重算 15 / 30 分钟可评分标签，与输入标签一致
时间核对	有效行无未来更新时间，距决策时刻不超过 300 秒

新文件中最近一年为 280,317 行、275,649 行有效；旧年表为 280,320 行、278,557 行有效。共有 2,905 条原有效行改为无效；1,856 条空位值发生变化，但全部属于新文件无效行。因此旧年度报告保留为历史记录，本次一年对照必须从新文件重跑。

所有 snapshot_time 都与决策时刻相同，来源字段统一为 api/data.gov.sg。以上仅验证 CSV 内部一致性，仍需原始 JSON 快照和修正日志确认采集与修正过程。缺少的 PRM 时点为 2026-04-20 14:30、14:45、15:00，不插补跨段训练。

评估口径

预测按“停车场 × 出发时点”评分，要求标签处于同一连续有效段；推荐按一个出发时点的候选集合评分，检查有效出发和到达端点。推荐结果是历史快照回放，不是实际司机追踪；距离为直线距离，Top3 可行率也不模拟依次寻位的额外时间。

配对统计以新加坡日期为整块，重采样 10,000 次，输出 95% percentile bootstrap 区间；双侧按日符号翻转 p 值在各比较 CSV 内做 Holm 校正，区间未做多重校正。日期块被视为可交换，检验假定日间独立、零假设下日差值对称；跨日依赖未建模。全零差异不输出可被误读为等效证明的区间或 p 值。

组员使用与结论

建议把完整两年标准运行作为 proposal 主测评，把同测试期的一年与两年实验作为补充消融。可以说“两年训练历史小幅改善占用率 MAE”；不能说“更多数据已经全面改善停车风险与推荐”。下一步应在预先确定的新日期、多个目的地和高需求场景继续检验。

仓库保留三组汇总、统计表、审计、5 张报告图与 PDF，A / B / C 一键运行及比较脚本齐全。原始大表、逐时点预测和模型在本地，未公开上传。完整数据复现入口为 scripts/run_history_comparison.py；43 项测试通过。

复现命令与结果文件 · 数据审计 · 实验清单 · 软件版本